



FACULTAD DE CIENCIAS EXACTAS Y NATURALES Y AGRIMENSURA
UNIVERSIDAD NACIONAL DEL NORDESTE
Doctorado en Informática — UNNE · UNaM · UTN FRRe

Introducción al Aprendizaje de Máquina

TRABAJO INTEGRADOR

**Predicción de demanda de prestaciones de enfermería a partir de datos abiertos
municipales**

INTEGRANTES	DOCENTE
Sofía Vallejos Cecilia Soto	Dr. Eduardo Zamudio

2026

Índice

Integrantes	2
Objetivos	2
Objetivo general	2
Objetivos específicos	2
Metodología de desarrollo	2
Herramientas	3
Resultados	4
Distribución de la variable objetivo	4
Regresión lineal, Lasso y Ridge	4
Clasificación binaria: regresión logística	5
Clasificación binaria: Máquinas de Vector Soporte	5
Conclusiones	5

1. Integrantes

- Sofía Vallejos
- Cecilia Soto

2. Objetivos

Objetivo general

Aplicar algoritmos de regresión, clasificación y máquinas de vector soporte sobre un caso real de datos públicos de gestión municipal, evaluando en qué medida permiten predecir la demanda de un servicio de salud a partir de información administrativa disponible.

Objetivos específicos

- Caracterizar y preprocesar el conjunto de datos "Prestaciones de Enfermería" del portal de datos abiertos de la Municipalidad de Corrientes (7408 registros).
- Implementar y comparar algoritmos de regresión lineal (Lasso, Ridge) para predecir la cantidad de consultas, evaluando el efecto de la regularización sobre el error de generalización.
- Reformular el problema como uno de clasificación binaria, utilizando la mediana como umbral de discretización, y comparar el desempeño de la regresión logística bajo distintos valores de C y de penalización (l_1 , l_2).
- Implementar y comparar Máquinas de Vector Soporte con distintos kernels (lineal, polinomial, radial) sobre ese mismo problema de clasificación.
- Documentar el proceso en un repositorio de control de versiones compartido con la cátedra.

3. Metodología de desarrollo

El dataset reúne registros mensuales de prestaciones de enfermería correspondientes a 34 centros de salud (SAPS) de la Municipalidad de Corrientes, entre enero de 2023 y mayo de 2026. Para cada centro, mes y tipo de prestación (control de tensión arterial, glucemia, curaciones, entre otros) se registra la cantidad de consultas efectivamente realizadas.

Esa variable, `consulta_cantidad`, se utilizó de dos maneras distintas a lo largo del trabajo: como variable continua para la tarea de regresión, y discretizada mediante su mediana (44 consultas) para las tareas de clasificación binaria. Nos pareció un criterio razonable porque, además de ser interpretable, produjo una partición prácticamente equilibrada entre ambas clases ($\approx 50\%/50\%$), lo que permite utilizar accuracy sin el riesgo de que una clase mayoritaria distorsione la lectura de los resultados.

Previo al modelado fue necesario un preprocesamiento breve: la columna `barrio_operativo` se encontró completamente vacía en este recorte del dataset, por lo que se decidió descartarla; asimismo, se identificó un único registro sin valor de `consulta_cantidad`, que se excluyó por no contar con un criterio de imputación sólido.

Como variables predictoras categóricas se utilizaron el centro de salud, la categoría y el tipo de prestación, codificadas mediante One-Hot Encoding; como numéricas, el mes, el año y un código de servicio, estandarizadas. Cabe aclarar que este último código (`id_servicio`) coincide exactamente con la categoría de prestación —toma el valor 4 para todos los registros de ENFERMERIA y 10 para los de GINECOLOGIA—, por lo que en la práctica no aporta información adicional a la ya provista por `prestacion_categoria`. Se decidió mantenerlo de todas formas dentro del conjunto de variables numéricas, ya que no distorsiona los resultados, aunque una versión más depurada del pipeline podría prescindir de él.

Todo el preprocesamiento se integró en un Pipeline de scikit-learn junto con un ColumnTransformer, de modo que el ajuste de las transformaciones se realice exclusivamente sobre el conjunto de entrenamiento, evitando así la fuga de información hacia el conjunto de prueba.

El desarrollo se organizó en tres etapas:

- Regresión lineal, comparando Lasso y Ridge con distintos valores de regularización (α).
- Regresión logística, con una grilla de valores de C (0.01, 0.1, 1 y 10) combinados con penalización $l1$ y $l2$.
- Máquinas de Vector Soporte, comparando los kernels lineal, polinomial y radial (RBF).


El desarrollo completo, con el código y las salidas de cada ejecución, se encuentra documentado en el notebook "`TFI_Prestaciones_Enfermeria.ipynb`". Se incluyen además en el repositorio dos versiones del dataset: "`prestaciones_enfermeria_original.csv`" (fuente sin modificar, 7408 registros) y "`prestaciones_enfermeria_procesado.csv`" (7407 registros, ya con la limpieza aplicada), con el propósito de dejar constancia del efecto concreto del preprocesamiento sobre los datos.

4. Herramientas

- Python 3
- scikit-learn, para la implementación de los modelos de regresión, clasificación y SVM
- pandas y NumPy, para la manipulación de los datos
- Matplotlib y Seaborn, para la visualización
- Jupyter Notebook
- Git / GitHub, para el control de versiones y el repositorio compartido con la cátedra

5. Resultados

Distribución de la variable objetivo



La variable `consulta_cantidad` presenta una distribución marcadamente asimétrica: la media (≈ 101) se ubica muy por encima de la mediana (44), y el máximo alcanza las 2890 consultas en un mismo centro y tipo de prestación en un mes dado. Se trata de un comportamiento habitual en datos de demanda de servicios, y conviene tenerlo presente al interpretar el error cuadrático medio de la sección siguiente, dado que este tipo de distribución tiende a otorgar mayor peso a los valores extremos.

El boxplot de la misma figura, discriminado por categoría de prestación, deja ver además que GINECOLOGIA es una categoría marginal dentro del dataset: apenas 57 registros frente a los 7350 de ENFERMERIA, con una demanda mensual sensiblemente menor (media ≈ 7.5 , máximo 50). No incide sobre la definición del target, pero conviene tenerlo presente al pensar en cuánto peso real puede tener esta variable dentro de los modelos entrenados.

Regresión lineal, Lasso y Ridge

Modelo	MSE	R ²
LinearRegression (sin regularización)	19186.65	0.4320
Ridge (alpha=0.1)	19187.65	0.4320
Ridge (alpha=1.0)	19197.01	0.4317
Lasso (alpha=0.1)	19291.13	0.4289
Ridge (alpha=10.0)	19315.48	0.4282
Lasso (alpha=1.0)	20686.35	0.3876
Lasso (alpha=10.0)	26002.15	0.2302

En conjunto, el modelo lineal explica alrededor del 43% de la varianza de la variable objetivo. Los mejores resultados corresponden al modelo sin regularización y a Ridge con alpha bajo, prácticamente indistinguibles entre sí; consideramos que esto indica que, con las variables disponibles, no hay una multicolinealidad ni un sobreajuste lo suficientemente marcados como para que la regularización aporte una mejora sustancial. A medida que el valor de alpha aumenta, en cambio, el desempeño se deteriora con claridad —particularmente en Lasso, donde en alpha=10 se descartan demasiados coeficientes y el R² cae a 0.23—, lo que resulta coherente con un caso de subajuste progresivo.

Clasificación binaria: regresión logística

C	Penalización	Accuracy	F1
1.0	l2	0.8394	0.8370
0.1	l1	0.8387	0.8362
1.0	l1	0.8381	0.8358
10.0	l1	0.8374	0.8353
10.0	l2	0.8374	0.8353
0.1	l2	0.8293	0.8259
0.01	l2	0.8151	0.8087
0.01	l1	0.7800	0.7527

Los valores más bajos de C —es decir, mayor regularización— perjudican el desempeño de forma notoria, en particular bajo penalización $l1$, que en este caso reduce a cero una cantidad considerable de coeficientes dentro de las 57 variables resultantes del preprocesamiento (54 provenientes del One-Hot Encoding de `saps`, `prestacion_categoria` y `prestacion_tipo`, más 3 numéricas estandarizadas). A partir de $C=0.1$ el modelo se estabiliza en torno al 83-84% de accuracy, con diferencias mínimas entre $l1$ y $l2$, lo que sugiere que la mayoría de las variables aporta información relevante y no es necesaria una regularización fuerte para evitar el sobreajuste en este problema.

Clasificación binaria: Máquinas de Vector Soporte

Kernel	Accuracy	F1
poly	0.8887	0.8886
rbf	0.8853	0.8862
linear	0.8347	0.8334

A diferencia de lo observado con la regularización, aquí la diferencia es considerable: los kernels polinomial y radial superan al lineal por cerca de cinco puntos porcentuales de accuracy. Interpretamos este resultado como un indicio de que la frontera de decisión entre "alta" y "baja" demanda no es linealmente separable en el espacio de características construido, y que existen interacciones entre el centro de salud, el tipo de prestación y el período que un modelo lineal no logra capturar.

6. Conclusiones

De las tres etapas desarrolladas, la que arrojó el hallazgo más relevante fue la comparación de kernels en SVM. Conviene aclarar un matiz sobre este punto: si se compara todo el rango de C probado en la regresión logística, incluido el valor más extremo ($C=0.01$), la diferencia de desempeño llega a casi 6 puntos porcentuales —similar a la que aporta el cambio de kernel—, pero ese salto corresponde a un caso de regularización excesiva, poco representativo de una

búsqueda de hiperparámetros razonable. Si en cambio se compara únicamente entre los valores de C que efectivamente conviene considerar (0.1 en adelante), la diferencia se reduce a apenas un punto porcentual, mientras que pasar de un kernel lineal a uno no lineal en SVM sigue aportando cerca de cinco puntos. Nos parece que esa es la comparación más justa, y de ahí concluimos que, en este problema, la elección de la familia de modelo pesa más que el ajuste fino de sus hiperparámetros.

En la tarea de regresión los resultados son más modestos: un R^2 de 0.43 deja una porción considerable de la variación sin explicar, lo cual atribuimos más a la ausencia de variables adicionales —por ejemplo, indicadores sociodemográficos por barrio— que a limitaciones del ajuste del modelo en sí.

En conjunto, consideramos que el trabajo confirma la viabilidad de construir modelos predictivos razonables a partir de datos abiertos municipales, y que constituye un punto de partida metodológico coherente con la línea de análisis de comportamiento ciudadano que orienta nuestra investigación doctoral.